

Análisis lingüístico de los errores de cuatro motores OCR

Tipos de error, preservación de entidades y estabilidad entre documentos

1 Introducción

La comparación cuantitativa habitual entre motores OCR resume el desempeño en la tasa de error de caracteres (CER), la tasa de error de palabras (WER) y el tiempo por página. Estas métricas son útiles para escoger un motor, pero promedian todos los errores por igual: dos motores con un CER similar pueden equivocarse de maneras muy distintas y conservar información muy distinta. Para tareas administrativas concretas, como recuperar nombres en un padrón, ubicar fechas en una resolución o localizar identificadores en un formulario, el promedio es insuficiente.

Este reporte propone un análisis complementario sobre documentos administrativos colombianos del siglo XX. En lugar de reducir cada motor a unos pocos números, caracteriza su comportamiento erróneo desde tres dimensiones: los tipos de error a nivel de carácter, la preservación de entidades administrativas y la estabilidad del error entre documentos. La pregunta cambia de qué motor tiene menor error promedio a qué motor preserva mejor la información que la tarea exige. Se comparan 4 motores (Tesseract, EasyOCR, PaddleOCR y OlmOCR) sobre los mismos 30 folios en imagen original; CER y WER se incluyen solo como contexto. Un experimento adicional con imágenes preprocesadas se presenta como análisis complementario ([Sección 3.5](#)).

2 Datos y métodos

2.1 Corpus y motores

El corpus consta de 30 folios de documentos administrativos del siglo XX. Para cada folio se dispone de la transcripción manual de referencia y de la salida de cada uno de los cuatro motores. Los motores se ejecutaron previamente: este reporte no ejecuta OCR, recibe las salidas en texto plano alineadas con la referencia, folio por folio, y se concentra en el análisis posterior, implementado en R.

El análisis principal usa la imagen original de los 30 folios, de modo que los cuatro motores se comparan bajo exactamente la misma entrada: $30 \text{ folios} \times 4 \text{ motores} = 120 \text{ observaciones}$. Los datos incluyen además las salidas de una versión preprocesada de las mismas imágenes (240 observaciones en total), que solo se utiliza en el análisis complementario y en el apéndice.




Figura 1. Flujo del análisis lingüístico. Los 30 folios en imagen original se procesan con 4 motores OCR, lo que produce 120 comparaciones entre la transcripción de referencia y la salida OCR; cada comparación alimenta los tres análisis por motor: errores de carácter, preservación de entidades y estabilidad entre folios.

2.2 Normalización y métricas auxiliares

El CER es la distancia de Levenshtein a nivel de carácter entre la referencia y la salida del motor, dividida por la longitud de la referencia; el WER se define igual a nivel de palabra. La normalización es mínima: los saltos de línea CRLF y CR pasan a LF, los espacios consecutivos se reducen a uno y se recortan los extremos. No se corrige la ortografía, no se eliminan las tildes y la puntuación se conserva en el cálculo del CER.

Para clasificar los errores de carácter se recuperan las operaciones de edición (sustitución, omisión e inserción) con `adist()`. La distancia total obtenida a partir de esas operaciones se validó contra `string-dist`: sobre las 240 salidas disponibles hubo 0 discrepancias.

2.3 Análisis lingüístico en R

El análisis se organiza en tres componentes que se aplican a cada motor:

- Errores de carácter.** Composición del error en sustituciones, omisiones e inserciones, y matriz de confusiones entre el carácter de referencia y el carácter OCR. Para su lectura, cada sustitución se agrupa según los caracteres implicados: confusión entre letras, tildes y diacríticos, letra por dígito, comillas y apóstrofes, puntuación u otras; esta agrupación no altera los conteos.
- Preservación de entidades administrativas.** Fechas, números, nombres propios y códigos administrativos se extraen de la referencia con `quanteda`, expresiones regulares y un diccionario léxico revisado manualmente, y se buscan en cada salida. La comparación no distingue mayúsculas, no elimina tildes, no corrige el texto OCR y no equipara caracteres visualmente parecidos. La tasa de preservación es la proporción de entidades de la referencia presentes en la salida.
- Estabilidad entre documentos.** Distribución del CER y del WER entre los folios de cada motor, resumida con la mediana, el rango intercuartílico (IQR), el percentil 90 (P90) y el máximo, sin excluir valores extremos ni truncar las tasas en 1.

`tidytext` aporta la integración tabular a nivel de token (apéndice), `tidyverse` organiza las estructuras de datos, `ggplot2` produce las visualizaciones y Quarto compila el reporte a partir de los resultados ya

calculados.

3 Resultados

3.1 CER y WER como contexto cuantitativo

Estas métricas permiten situar el desempeño global de cada motor, pero no explican la naturaleza del error.




Figura 2. CER y WER por motor en condición original. El punto marca la mediana entre los 30 folios y la línea, el rango intercuartílico (percentiles 25 a 75). Un valor menor indica menor error. Cada panel tiene su propia escala horizontal.

En la condición original, la mediana del CER va de 0,5 % (OlmOCR) a 6,1 % (EasyOCR) y la del WER, de 1,6 % (OlmOCR) a 20,6 % (EasyOCR). El orden de los motores de menor a mayor error es el mismo para ambas métricas, y el WER mediano supera al CER mediano en todos los motores, como es esperable: un solo carácter erróneo invalida la palabra completa. Los rangos intercuartílicos del CER se solapan en PaddleOCR–Tesseract, por lo que la diferencia entre esos motores debe leerse con cautela. Los siguientes tres análisis constituyen el núcleo del estudio.

3.2 Errores a nivel de carácter




Figura 3. Composición de los errores de carácter por motor, en condición original. Cada barra suma el 100 % de las operaciones de edición de un motor y se reparte entre sustituciones, omisiones e inserciones; el número a la derecha es el total de operaciones. La figura compara la composición, no el volumen de errores.

La composición del error difiere entre motores más de lo que sugieren sus tasas globales: predominan las inserciones en Tesseract, EasyOCR y PaddleOCR; predominan las omisiones en OlmOCR. En OlmOCR las omisiones son el 66,9 % de sus operaciones de edición; en PaddleOCR, las inserciones son el 68,8 %. El volumen también varía: el total de operaciones va de 864 (OlmOCR) a 4.913 (EasyOCR), como muestra la tabla.

Operaciones de edición por motor y tipo de error, en condición original.

Motor	Sustituciones	Omisiones	Inserciones	Total
Tesseract	596	696	869	2.161
EasyOCR	1.811	940	2.162	4.913
PaddleOCR	304	74	835	1.213
OlmOCR	186	578	100	864




Figura 4. Principales sustituciones de carácter por motor, en condición original. Cada panel muestra las ocho sustituciones más frecuentes del motor; la barra indica cuántas veces el carácter de la referencia fue reemplazado por el carácter OCR indicado y el color, el tipo de sustitución. Cada panel tiene su propia escala horizontal.

La sustitución más frecuente de cada motor es: Tesseract, comilla recta → apóstrofo recto (73); EasyOCR, a → e (211); PaddleOCR, í → i (82); OlmOCR, comilla recta → comilla curva izq. (24). Tres patrones lingüísticos se distinguen. Primero, las sustituciones que confunden una letra con un dígito (por ejemplo, l por 1, o por 0 o s por 8) representan el 2,3 % en Tesseract, 23,6 % en EasyOCR, 5,8 % en PaddleOCR y 4,1 % en OlmOCR de las sustituciones; este tipo de confusión compromete números y códigos. Segundo, las sustituciones asociadas a tildes y diacríticos (í por i, ó por o, i por í) representan el 17,8 % en Tesseract, 9,5 % en EasyOCR, 48,1 % en PaddleOCR y 19,2 % en OlmOCR. Tercero, las que solo cambian el tipo de comilla o apóstrofo representan el 32,3 % en Tesseract, 1,4 % en EasyOCR, 1,4 % en PaddleOCR y 27,3 % en OlmOCR; son variantes tipográficas que no alteran la palabra transcrita. También aparece, como salida en lugar de guion, un ideograma chino (U+4E00) en PaddleOCR (7 sustituciones).

3.3 Preservación de entidades administrativas




Figura 5. Preservación de entidades administrativas por motor y categoría, en condición original. El color y el porcentaje indican la proporción de entidades de la referencia presentes en la salida del motor; debajo se muestra el número de entidades preservadas sobre el número evaluado en la categoría. Un valor mayor indica mejor preservación.

- **Fechas** (n = 5): entre 60 % (EasyOCR) y 100 % (Tesseract).
- **Números** (n = 127): entre 71 % (OlmOCR) y 98 % (PaddleOCR).
- **Nombres propios** (n = 223): entre 70 % (EasyOCR) y 94 % (OlmOCR).
- **Códigos administrativos** (n = 11): entre 64 % (EasyOCR) y 100 % (Tesseract).

Un menor CER no garantiza una mejor preservación de la información administrativa. El motor con menor CER mediano (OlmOCR) no es el que mejor preserva fechas y números; su valor más bajo es 71 % en números. El error promedio no anticipa, por tanto, la conservación de las entidades que una tarea administrativa necesita.

Las categorías con pocas entidades (fechas, n = 5 y códigos administrativos, n = 11) son sensibles a un solo acierto o error: en ellas una entidad equivale a 20,0 pp o 9,1 pp, según la categoría. Las diferencias entre motores en esas categorías no deben tomarse como concluyentes.

3.4 Estabilidad entre documentos

¿Es el desempeño de cada motor consistente entre documentos?

Distribución del CER y del WER entre folios, en condición original (IQR: rango intercuartílico; P90: percentil 90; máx.: valor máximo).

Motor	CER mediana	CER IQR	CER P90	CER máx.	WER mediana	WER		
						WER IQR	P90	WER máx.
Tesseract	3,0 %	2,4 %	6,5 %	56,0 %	12,4 %	6,7 %	24,4 %	61,7 %
EasyOCR	6,1 %	4,6 %	20,0 %	41,2 %	20,6 %	12,9 %	70,2 %	91,5 %

Motor	CER mediana	CER IQR	CER P90	CER máx.	WER			
					WER mediana	WER IQR	P90	WER máx.
PaddleOCR	1,6 %	2,5 %	4,0 %	27,1 %	9,6 %	5,4 %	17,4 %	61,7 %
OlmOCR	0,5 %	0,8 %	4,9 %	27,5 %	1,6 %	4,2 %	7,4 %	38,3 %




Figura 6. Distribución del CER y del WER entre folios por motor, en condición original. Cada punto es un folio (30 por motor); la caja marca la mediana y el rango intercuartílico. No se excluyeron valores extremos y se rotula el folio con mayor error en cada motor. Cada panel tiene su propia escala vertical.

La dispersión del error entre folios es tan relevante como su nivel. El IQR del CER va de 0,8 % (OlmOCR) a 4,6 % (EasyOCR) y el máximo por folio, de 27,1 % (PaddleOCR) a 56,0 % (Tesseract). En OlmOCR el CER máximo equivale a 51 veces su mediana: un motor con buen desempeño típico puede fallar de forma grave en un documento concreto. Los folios con mayor CER son Tesseract (Folio_18, 56,0 %); EasyOCR (Folio_18, 41,2 %); PaddleOCR (Folio_18, 27,1 %); OlmOCR (Folio_18, 27,5 %). Folio_18 es el de mayor CER en todos los motores, lo que sugiere que parte de la dificultad es propia del documento y no solo del motor.

3.5 Análisis complementario del preprocesamiento

Además de la imagen original, se evaluó una versión preprocesada común de las mismas imágenes con los cuatro motores (120 observaciones adicionales), para explorar si una normalización visual externa modifica el desempeño.

Efecto del preprocesamiento por motor. Los cambios se expresan en puntos porcentuales (pp) como preprocesada menos original; un valor negativo indica menor error.

Motor	CER mediano original	CER mediano preprocesada	Cambio en CER mediano	Cambio en WER mediano	Cambio en IQR del CER
-------	----------------------	--------------------------	-----------------------	-----------------------	-----------------------

Motor	CER mediano original	CER mediano preprocesada	Cambio en CER mediano	Cambio en WER mediano	Cambio en IQR del CER
Tesseract	3,0 %	2,6 %	-0,34 pp	-0,14 pp	-0,40 pp
EasyOCR	6,1 %	6,2 %	+0,10 pp	-0,28 pp	+0,41 pp
PaddleOCR	1,6 %	1,8 %	+0,17 pp	+0,65 pp	-0,38 pp
OlmOCR	0,5 %	0,8 %	+0,24 pp	+1,18 pp	+0,32 pp

El preprocesamiento tuvo un efecto pequeño y no uniforme entre motores y folios. El CER mediano disminuyó ligeramente en Tesseract y aumentó en EasyOCR, PaddleOCR y OlmOCR, de modo que no hubo una mejora general. Los cambios agregados van de -0,34 pp a +0,24 pp, magnitudes menores que la variabilidad natural entre documentos (el IQR del CER en condición original es mayor en todos los motores). Sí existieron efectos particulares importantes por folio: el mayor es el de Folio_18 con Tesseract, cuyo CER pasa de 56,0 % a 100,0 % (+44,0 pp). El detalle por motor y por folio se presenta en el apéndice.

Hipótesis, no contrastada con estos datos. Una posible explicación es que algunos motores incorporen tratamiento visual propio, por lo que una normalización externa común no necesariamente aporta una mejora y puede modificar señales útiles.

4 Alcances y límites

El estudio se basa en 30 folios de un solo corpus y en una referencia transcrita manualmente, por lo que los resultados describen este conjunto y no deben extrapolarse sin validación a otros tipos de documento. El análisis principal compara los motores sobre una única entrada (la imagen original); el análisis complementario evalúa una sola configuración de preprocesamiento, común a todos los motores, y no permite atribuir causas a sus efectos. Las categorías de entidades tienen tamaños muy desiguales (fechas: 5, números: 127, nombres propios: 223 y códigos administrativos: 11), de modo que las tasas de las categorías pequeñas son poco precisas. Finalmente, la comparación de entidades es exacta, sin tolerancia a variantes, lo que penaliza incluso diferencias menores de forma.

5 Conclusiones

Los motores difieren no solo en cuánto fallan sino en cómo fallan. Sus perfiles de error de carácter son distintos: en la condición original predominan las inserciones en Tesseract, EasyOCR y PaddleOCR; predominan las omisiones en OlmOCR, y las confusiones más frecuentes también cambian de un motor a otro. CER y WER no anticipan necesariamente la preservación de entidades: el motor con menor CER mediano (OlmOCR) no es el mejor en la preservación de fechas y números (con la reserva de que algunas categorías tienen pocas entidades). La estabilidad entre documentos también cambia por motor: el CER máximo por folio va de 27,1 % (PaddleOCR) a 56,0 % (Tesseract), y en OlmOCR equivale a 51 veces la mediana.

Por eso, seleccionar un OCR para documentos administrativos depende de qué información necesita preservar la tarea y de cuánto costaría un fallo grave en un documento individual, más que del error promedio. El estudio no declara un motor ganador general.

El experimento adicional de preprocesamiento mostró un efecto pequeño y no uniforme y, por tanto, no modifica las conclusiones centrales del análisis lingüístico.

Apéndice

A. CER y WER completos

CER y WER por motor y condición.

Motor	Condición	Folios	CER medio	CER mediano	WER medio	WER mediano
Tesseract	Original	30	5,6 %	3,0 %	15,5 %	12,4 %
Tesseract	Preprocesada	30	6,3 %	2,6 %	15,7 %	12,3 %
EasyOCR	Original	30	9,2 %	6,1 %	30,7 %	20,6 %
EasyOCR	Preprocesada	30	9,2 %	6,2 %	30,4 %	20,3 %
PaddleOCR	Original	30	2,9 %	1,6 %	11,9 %	9,6 %
PaddleOCR	Preprocesada	30	2,9 %	1,8 %	12,1 %	10,3 %
OlmOCR	Original	30	2,4 %	0,5 %	4,1 %	1,6 %
OlmOCR	Preprocesada	30	2,7 %	0,8 %	4,8 %	2,8 %

B. Estabilidad entre folios en ambas condiciones

Distribución del CER y del WER entre folios por motor y condición.

Motor	Condición	CER mediana	CER IQR	CER P90	CER máx.	WER mediana	WER IQR	WER P90	WER máx.
Tesseract	Original	3,0 %	2,4 %	6,5 %	56,0 %	12,4 %	6,7 %	24,4 %	61,7 %
Tesseract	Preprocesada	2,6 %	2,0 %	5,2 %	100,0 %	12,3 %	9,0 %	21,7 %	100,0 %
EasyOCR	Original	6,1 %	4,6 %	20,0 %	41,2 %	20,6 %	12,9 %	70,2 %	91,5 %
EasyOCR	Preprocesada	6,2 %	5,0 %	18,9 %	38,7 %	20,3 %	13,3 %	65,9 %	95,7 %
PaddleOCR	Original	1,6 %	2,5 %	4,0 %	27,1 %	9,6 %	5,4 %	17,4 %	61,7 %
PaddleOCR	Preprocesada	1,8 %	2,1 %	4,3 %	23,9 %	10,3 %	5,9 %	17,9 %	57,4 %
OlmOCR	Original	0,5 %	0,8 %	4,9 %	27,5 %	1,6 %	4,2 %	7,4 %	38,3 %

Motor	Condición	CER	CER	CER	CER	WER	WER	WER	WER
		mediana	IQR	P90	máx.	mediana	IQR	P90	máx.
OlmOCR	Preprocesada	0,8 %	1,1 %	5,3 %	27,5 %	2,8 %	4,7 %	7,3 %	38,3 %

C. Composición del error en ambas condiciones




Figura A1. Conteo y proporción de cada tipo de error por motor y condición. Cada celda muestra el número de operaciones de edición y su porcentaje sobre el total de errores de esa combinación; el color más oscuro indica una proporción mayor.

D. Efecto del preprocesamiento: detalle




Figura A2. Medidas resumen por motor en la condición original (azul) y en la preprocesada (naranja), unidas por un segmento. Cada panel tiene su propia escala horizontal. Un desplazamiento del punto naranja hacia la izquierda indica reducción del error.




Figura A3. Cambio del CER de cada folio al pasar de la condición original a la preprocesada. Cada punto gris es un folio y el rombo naranja, la mediana del cambio; los valores negativos indican menor error tras el preprocesamiento. Cada panel tiene su propia escala horizontal y se rotulan los dos folios con mayor cambio absoluto.

E. Principales sustituciones por motor y condición

Cinco sustituciones más frecuentes de cada condición dentro de cada motor.

Tesseract	EasyOCR	PaddleOCR	OlmOCR
Condición	Referencia	OCR	Frecuencia
Original	comilla recta	apóstrofo recto	73
Original	í	i	62
Original	comilla recta	comilla curva der.	59
Original	comilla recta	comilla curva izq.	52
Original	.	,	47
Preprocesada	comilla recta	apóstrofo recto	74
Preprocesada	comilla recta	comilla curva der.	59

Condición	Referencia	OCR	Frecuencia
Preprocesada	í	i	56
Preprocesada	comilla recta	comilla curva izq.	52
Preprocesada	.	,	46

F. Preservación de entidades por categoría y condición

Fechas	Números	Nombres propios	Códigos administrativos	
Motor	Condición	Entidades de referencia	Preservadas	Tasa
Tesseract	Original	5	5	100 %
Tesseract	Preprocesada	5	5	100 %
EasyOCR	Original	5	3	60 %
EasyOCR	Preprocesada	5	3	60 %
PaddleOCR	Original	5	5	100 %
PaddleOCR	Preprocesada	5	5	100 %
OlmOCR	Original	5	4	80 %
OlmOCR	Preprocesada	5	4	80 %

G. Integración tabular con tidytext

Con `tidytext::unnest_tokens()` se construyó una tabla de tokens para la referencia y para cada salida OCR. Esta capa no modifica CER ni WER; permite observar cuánto texto y cuánto vocabulario distinto produce cada motor frente a la referencia.

Volumen de tokens totales y únicos por motor y condición.

Motor	Condición	Tokens referencia	Tokens OCR	OCR / referencia	Únicos referencia	Únicos OCR	OCR / referencia
Tesseract	Original	9.579	9.786	102 %	2.988	3.340	112 %
Tesseract	Preprocesada	9.579	9.806	102 %	2.988	3.344	112 %

Motor	Condición	Tokens referencia	Tokens OCR	OCR / referencia	Únicos referencia	Únicos OCR	OCR / referencia
EasyOCR	Original	9.579	10.059	105 %	2.988	3.830	128 %
EasyOCR	Preprocesada	9.579	10.091	105 %	2.988	3.822	128 %
PaddleOCR	Original	9.579	9.912	103 %	2.988	3.382	113 %
PaddleOCR	Preprocesada	9.579	9.907	103 %	2.988	3.380	113 %
OlmoOCR	Original	9.579	9.494	99 %	2.988	2.938	98 %
OlmoOCR	Preprocesada	9.579	9.484	99 %	2.988	2.944	99 %

H. Reproducibilidad

El análisis completo se regenera con `Rscript docs/LatinR/R/run_latintr_analysis.R` y las rutas, motores y condiciones se definen en `config.yml`. Este reporte solo lee los resultados de `resultados/`, aplica el filtro de condición en la capa de presentación y no ejecuta ningún motor OCR.